

ViAmpleHate: Phương pháp đề xuất dựa trên AmpleHate và PhoBERT cho Phát hiện Phát ngôn Thù ghét Tiếng Việt

Tran Nguyen Duc Trung Nguyen Ha Minh Tuan Nguyen Gia Cat Long
Tran Phan Thanh Tung Mo Van Tung

Trường Đại học Công nghệ Thông tin, ĐHQG-HCM, Thành phố Hồ Chí Minh, Việt Nam
{23521687, 23521718, 23520881, 23521747, 23521741}@gm.uit.edu.vn

Abstract

Phát hiện phát ngôn thù ghét trên mạng xã hội tiếng Việt là một bài toán khó, bởi ý đồ thù ghét hiếm khi bộc lộ qua thực thể có tên mà thường ẩn sau cách gọi nhóm phi chính thức, tiếng lóng, lối nói mỉa mai và những ám chỉ gián tiếp. Các mô hình *target-aware* (nhận biết mục tiêu) như AmpleHate đã chỉ ra rằng nếu cho mô hình attention vào quan hệ giữa phát ngôn và đối tượng mà nó hướng tới thì có thể phát hiện được cả những trường hợp thù ghét hàm ẩn. Tuy nhiên, pipeline gốc của AmpleHate lại dựa trên NER (nhận dạng thực thể có tên) và các phạm trù mục tiêu theo kiểu tiếng Anh, nên khi chuyển sang tiếng Việt thì hiệu quả giảm hẳn: trên tập huấn luyện của nhóm, NER tiếng Anh chỉ tìm được mục tiêu khả dụng ở khoảng 0,09% số bình luận, khiến mô hình thoái hóa thành một classifier câu thông thường. Nhóm đề xuất **ViAmpleHate**, một phiên bản thích ứng của AmpleHate cho tiếng Việt trên nền PhoBERT, với bốn thay đổi chính: (i) thay NER tiếng Anh bằng NER tiếng Việt kết hợp một *target-cue bank* được tuyển chọn, qua đó nâng độ phủ mục tiêu lên khoảng 19–45% tùy bộ dữ liệu; (ii) bổ sung một *attack-cue bank* riêng và mô hình hóa ba kênh quan hệ—target tường minh, ngữ cảnh hàm ẩn và attack—thông qua một *relation-bank attention*; (iii) thay phép injection cố định bằng một *instance-adaptive gate*; và (iv) huấn luyện bằng weighted cross-entropy kết hợp contrastive loss. Trên ViHSD và VOZ-HSD (ở thiết lập nhị phân NON-HATE/HATE), ViAmpleHate cải thiện cả macro-F1 lẫn HATE-F1 so với baseline AmpleHate và các baseline TF-IDF, BiLSTM, PhoBERT-CNN, trong đó mức cải thiện rõ rệt nhất nằm ở lớp thiểu số (HATE-F1 tăng 0,0508 trên VOZ-HSD); riêng trên ViHSD mức cải thiện còn nhỏ nên nhóm chỉ xem là kết quả sơ bộ, cần kiểm chứng thêm bằng đánh giá

đa seed có kiểm soát. Phân tích sâu hơn cho thấy có mối liên hệ giữa độ phủ target-cue và mức cải thiện, củng cố cho quan điểm rằng cách mô hình hóa target-aware cần được thích ứng cho tiếng Việt thay vì bê nguyên từ tiếng Anh.

1 Giới thiệu

Mạng xã hội tiếng Việt phát triển nhanh kéo theo sự lan rộng của nội dung thù ghét, lăng mạ—gây hại cho cá nhân lẫn cộng đồng bị nhắm tới và đặt các nền tảng trước rủi ro pháp lý, danh tiếng. Khi lượng nội dung vượt xa khả năng kiểm duyệt thủ công, phát hiện thù ghét tự động trở thành nhu cầu cấp thiết. Dù vậy, phần lớn tiến bộ vẫn tập trung ở tiếng Anh cùng các ngôn ngữ giàu tài nguyên, và hiệu quả thường sụt giảm khi áp dụng cho tiếng Việt.

Phát hiện thù ghét trong tiếng Việt khó vì ba lý do đan xen. Thứ nhất, ngôn ngữ trên mạng xã hội rất nhiều: người dùng viết tắt, dùng *teencode*, kéo dài ký tự, chèn emoji mang sắc thái ngữ dụng và viết sai chính tả—thậm chí cố tình che lờ tục để né bộ lọc. Thứ hai, và cũng là điểm quan trọng nhất, *mục tiêu* (target) của một lời công kích hiếm khi là một thực thể có tên: nếu tiếng Anh thường gọi đích danh một cá nhân, tổ chức hay quốc tịch, thì trong tiếng Việt sự thù địch lại thường nhắm vào cả một nhóm thông qua đại từ, danh từ thân tộc hay danh từ chỉ nhóm, nhân vùng miền, hoặc các lối xưng hô phi chính thức. Thứ ba, dữ liệu mất cân bằng nặng: ở cả hai bộ dữ liệu, lớp HATE chỉ chiếm khoảng một phần mười, nên một mô hình hoàn toàn có thể đạt accuracy cao trong khi gần như không phát hiện được trường hợp thù ghét nào.

Một hướng hứa hẹn là mô hình hóa thù ghét theo kiểu *target-aware*. AmpleHate (Lee et al., 2025) cho thấy việc attention tường minh

vào quan hệ giữa câu và mục tiêu tiềm năng giúp phát hiện tốt hơn thù ghét *hàm ẩn*—loại không có slur lộ liễu. Cụ thể, nó trích target ứng viên bằng NER, tính một attention vector target-aware rồi inject vào biểu diễn câu trước khi phân loại. Hướng này rất hợp với tiếng Việt, nơi target giữ vai trò trung tâm; nhưng pipeline gốc lại xoay quanh NER và phạm trù target tiếng Anh. Khi chạy trên tiếng Việt với NER tiếng Anh, nó chỉ tìm được target khả dụng ở 21/24.048 bình luận huấn luyện (khoảng 0,09%), nên phần lớn đầu vào phải quay về biểu diễn toàn cục [CLS] và mô hình hoạt động chẳng khác một PhoBERT classifier thông thường, đánh mất chính tín hiệu target-aware.

Nhóm đề xuất **ViAmpleHate**, một phiên bản thích ứng của AmpleHate cho tiếng Việt, thiết kế lại từng khâu trong pipeline sao cho bám sát cách người Việt thực sự biểu đạt sự thù ghét. Các đóng góp chính gồm:

1. **Trích xuất target tiếng Việt.** Thay NER tiếng Anh bằng một mô hình NER tiếng Việt cùng một *target-cue bank* được tuyển chọn (gồm đại từ, danh từ chỉ nhóm và các lối xưng hô phi chính thức), qua đó nâng tỷ lệ bình luận phát hiện được target từ khoảng 0,09% lên 18,8–20,0%.
2. **Tách riêng kênh target và kênh attack.** Bổ sung một *attack-cue bank* cho các vị từ thù địch, đồng thời xử lý cue target và cue attack như hai tín hiệu độc lập thông qua một **relation-bank attention** ba kênh.
3. **Fusion thích ứng (kèm ghi chú triển khai).** Thay phép injection cố định theo hệ số vô hướng của AmpleHate bằng một **instance-adaptive gate**; bên cạnh đó, nhóm nêu thêm một chỉnh sửa ở mức triển khai cho phép tính attention theo batch trong bản port (chỉ xem là ghi chú triển khai, không phải đóng góp chính).
4. **Hàm mục tiêu huấn luyện.** Kết hợp weighted cross-entropy với một contrastive loss để làm rõ hơn ranh giới giữa HATE và NON-HATE trong điều kiện mất cân bằng.
5. **Nghiên cứu thực nghiệm.** Đánh giá trên ViHSD và VOZ-HSD với năm base-

line, đồng thời phân tích các mức cải thiện đến từ đâu và vì sao, bao gồm phân tích độ phủ target và khảo sát định tính các lỗi còn lại.

Thông điệp rộng hơn là: target-aware là một inductive bias hữu ích cho bài toán phát hiện thù ghét, nhưng chỉ thực sự phát huy khi được thích ứng với đặc trưng bề mặt của ngôn ngữ đích, thay vì bê nguyên từ tiếng Anh sang.

2 Công trình liên quan

2.1 Phát hiện phát ngôn thù ghét và thù ghét hàm ẩn

Các phương pháp phát hiện thù ghét tự động đã đi từ những classifier dựa trên từ điển và đặc trưng thủ công, qua các mô hình chuỗi sâu, đến những transformer tiền huấn luyện gần đây. Một trở ngại dai dẳng là thù ghét *hàm ẩn*: những thông điệp thể hiện thù địch mà không dùng slur tường minh, thay vào đó dựa vào mỉa mai, định kiến, tham chiếu được mã hóa hoặc kiến thức nội nhóm. Loại này thường gặp hơn cả slur lộ liễu và đặc biệt khó với các hệ thống dựa trên từ khóa, từ đó thúc đẩy những hướng tiếp cận biết lý giải *ai* bị nhắm tới và *theo cách nào*.

2.2 AmpleHate

AmpleHate (Lee et al., 2025) xử lý thù ghét hàm ẩn bằng cách khuếch đại attention giữa biểu diễn toàn cục của câu và các target ứng viên: nó trích target token bằng NER, tính một HeadAttention vector với query từ [CLS] và key/value từ target token, rồi inject với hệ số cố định trước khi phân loại. Ý tưởng cốt lõi—target là tín hiệu chịu tải chính—là nguồn cảm hứng cho công trình của nhóm. Hạn chế của nó với tiếng Việt cũng rõ: dùng NER và phạm trù target kiểu Anh, inject ở cường độ cố định cho mọi mẫu, và chỉ nắm bắt một quan hệ (target) mà bỏ qua vị từ thù địch (*attack*)—yếu tố biến một lời nhắc tên thành lời thù ghét.

2.3 Phát hiện phát ngôn thù ghét tiếng Việt

Tiếng Việt ngày càng có thêm nhiều tài nguyên và mô hình cho bài toán thù ghét. ViHSD (Luu et al., 2021) cung cấp một bộ dữ liệu ba lớp (CLEAN/OFFENSIVE/HATE) quy mô lớn và đã trở thành một benchmark tiêu chuẩn. ViTHSD (Vo et al., 2025) đặt lại bài toán xoay

quanh *target*, chú thích mức độ thù ghét nhắm vào từng *target*; điều này càng cho thấy vai trò trung tâm của *target* và ủng hộ cho thiết kế *target-aware* của nhóm. Khác với ViTHSD, ViAmpleHate không đòi hỏi chú thích *target* ở mức span: nó tự định vị *target* và *attack* bằng NER kết hợp cue bank, nên có thể áp dụng cho cả những bộ dữ liệu chỉ có nhãn ở mức câu.

2.4 PhoBERT và các mô hình tiền huấn luyện tiếng Việt

PhoBERT (Nguyen and Nguyen, 2020) là mô hình kiểu RoBERTa được tiền huấn luyện trên kho ngữ liệu tiếng Việt lớn, và hiện là encoder mặc định cho phân loại văn bản tiếng Việt. Do được huấn luyện trên văn bản đã *tách từ* (word segmentation), bước tách từ phải được thực hiện trước khi token hóa. Các kiến trúc lai như PhoBERT-CNN gắn thêm bộ trích đặc trưng cục bộ lên trên embedding ngữ cảnh. Nhóm dùng PhoBERT-base làm encoder chung cho cả baseline lẫn mô hình đề xuất, để mọi khác biệt về kết quả đều quy về cách mô hình hóa *target-aware* chứ không phải do backbone.

2.5 Contrastive learning cho phân loại văn bản

Các contrastive objective khuyến khích biểu diễn của những mẫu cùng lớp xích lại gần nhau và những mẫu khác lớp tách xa ra, nhờ đó cải thiện độ ổn định và mức tách biệt giữa các lớp, nhất là khi dữ liệu mất cân bằng (Khosla et al., 2020). Nhóm thêm một contrastive objective phụ trợ trên biểu diễn sau gate (post-gate), bên cạnh weighted cross-entropy—đây là một số hạng cosine-margin theo cặp, lấy cảm hứng từ supervised contrastive learning chứ không phải SupCon loss nguyên bản—nhằm siết chặt ranh giới giữa lớp NON-HATE phổ biến và lớp HATE hiếm gặp.

3 Bộ dữ liệu

3.1 ViHSD

ViHSD (Luu et al., 2021) là bộ dữ liệu phát ngôn thù ghét tiếng Việt gồm các bình luận mạng xã hội, được chú thích theo ba nhãn gốc (CLEAN, OFFENSIVE, HATE) và chia sẵn thành train/validation/test. Sau khi gán nhãn nhị phân (Mục 3.3), phân phối của từng tập được trình bày trong Bảng 1.

Bộ dữ liệu	Tập	NON-HATE	HATE	Tổng
ViHSD	Train	21.492	2.556	24.048
ViHSD	Dev	2.402	270	2.672
ViHSD	Test	5.992	688	6.680
VOZ	Train	26.993	3.007	30.000
VOZ	Dev	4.520	480	5.000
VOZ	Test	4.487	513	5.000

Table 1: Thống kê bộ dữ liệu sau khi gán nhãn nhị phân. Lớp HATE chiếm $\approx 10\%$ ở mọi tập, nên macro-F1/HATE-F1 quan trọng hơn accuracy.

3.2 VOZ-HSD

VOZ-HSD (Thanh Nguyen, 2024b), phát hành kèm ViHateT5 (Thanh Nguyen, 2024a), gồm các bình luận từ diễn đàn VOZ (lấy từ bản công khai tarudesu/VOZ-HSD). Tương tự ViHSD, dữ liệu cũng được chia thành train/validation/test, và phân phối sau khi gán nhãn lại nằm trong Bảng 1. Vì là tài nguyên của bên thứ ba, quy trình chú thích chi tiết cùng giấy phép của bộ dữ liệu được chính nhóm tác giả gốc công bố.

3.3 Gán nhãn nhị phân và tiền xử lý

Thao tác duy nhất nhóm thực hiện là *gán nhãn lại*. Nhóm đưa bài toán về phân loại nhị phân bằng cách gộp CLEAN và OFFENSIVE thành NON-HATE, đồng thời giữ HATE làm lớp dương. Cách làm này giúp tập trung vào thù ghét hướng nhóm (thay vì lời tục hay sự gây hấn nói chung) và tạo ra một không gian nhãn nhất quán giữa các bộ dữ liệu. Mỗi bình luận sau đó được chuẩn hóa (viết thường; bỏ URL và ký hiệu; gộp các ký tự bị kéo dài; chuẩn hóa teencode; ánh xạ các emoji thường gặp về những nhãn ngữ dụng thô như chế giễu, tức giận, ghê tởm hay cười cợt), rồi tách từ—bước bắt buộc vì PhoBERT vốn được tiền huấn luyện trên tiếng Việt đã tách từ—và cuối cùng token hóa bằng tokenizer của PhoBERT.

3.4 Xây dựng cue bank

Hai thành phần trung tâm của ViAmpleHate là *target-cue bank* và *attack-cue bank*, đều do nhóm xây dựng thủ công từ việc khảo sát tập train cùng các biểu thức tham chiếu, lắng mại phổ biến trong tiếng Việt, rồi chuẩn hóa cho khớp pipeline tiền xử lý. **Target-cue bank** gồm những biểu thức hay dùng để chỉ một người hoặc một nhóm—đại từ, danh từ thân tộc/chỉ nhóm, nhãn vùng miền và nhân khẩu, lối xưng hô phi chính thức—nhưng bản thân

chưa phải dấu hiệu thù ghét. **Attack-cue bank** gồm các vị từ thù địch: lăng mạ, phi nhân tính hóa, đe dọa, đánh giá tiêu cực gay gắt. Tách riêng hai bank là có dụng ý: một target không kèm vị từ thù địch thường không phải thù ghét, ngược lại vị từ thù địch mà không hướng tới target nhóm rõ ràng thì thường chỉ là xúc phạm. Mỗi cue được chuẩn hóa, tách từ, token hóa rồi đối sánh theo kiểu khớp trọn chuỗi token, nhờ đó một cụm nhiều token được khớp như một đơn vị thay vì khớp nhầm vào subtoken rời rạc. Hai bank cố ý giữ nhỏ, tuyển chọn thủ công—16 target cue và 24 attack cue (Phụ lục B). Do xuất phát từ dữ liệu train, chúng có thể vô tình mã hóa mẫu đặc thù của tập này và bị giới hạn recall trước tiếng lóng mới; độ phủ được báo cáo ở Mục 6.2.

4 Phương pháp

4.1 Phát biểu bài toán

Cho một bình luận tiếng Việt x , mô hình dự đoán $y \in \{\text{NON-HATE}, \text{HATE}\}$. ViAmpleHate kế thừa ý tưởng target-aware của AmpleHate và thích ứng nó qua năm thay đổi: trích xuất target tiếng Việt, tách riêng hai kênh target/attack cue, relation-bank attention, một phép tính attention theo batch đã được chỉnh sửa, và phép injection qua adaptive gate (Hình 1).

4.2 Tiền xử lý văn bản

Như đã nêu, mỗi bình luận được chuẩn hóa, tách từ, token hóa bằng tokenizer của PhoBERT, rồi cắt hoặc đệm về độ dài $\text{max_len} = 256$.

4.3 Trích xuất đa tín hiệu target và attack

Tập chỉ số target được hợp từ NER tiếng Việt và kết quả khớp target cue, còn tập chỉ số attack đến từ khớp attack cue. Nếu một trong hai tập rỗng, mô hình sẽ fallback về [CLS] để luôn có sẵn một biểu diễn hàm ẩn ở mức câu:

$$T_x = M_{\text{NER}}(x) \cup M_{\text{target}}(x), \quad A_x = M_{\text{attack}}(x) \quad (1)$$

$$T_x \leftarrow \{0\} \text{ nếu } T_x = \emptyset; \quad A_x \leftarrow \{0\} \text{ nếu } A_x = \emptyset$$

4.4 PhoBERT encoder

$$H = \text{PhoBERT}(x) = [h_0, h_1, \dots, h_n], \quad (2)$$

với mỗi $h_i \in \mathbb{R}^d$, $d = 768$; trong đó h_0 là biểu diễn [CLS] (context toàn cục), còn các vị trí target/attack đóng vai trò cung cấp bằng chứng cục bộ.

4.5 Relation-bank attention

Nhóm dựng ba góc nhìn quan hệ cho mỗi mẫu—target tường minh, context hàm ẩn và attack:

$$\begin{aligned} r_{\text{exp}} &= \text{HeadAttn}(h_0, H[T_x]), \\ r_{\text{imp}} &= \text{HeadAttn}(h_0, h_0), \\ r_{\text{atk}} &= \text{HeadAttn}(h_0, H[A_x]), \end{aligned} \quad (3)$$

trong đó mỗi module áp lên $E \in \mathbb{R}^{m \times d}$ và tính

$$\alpha = \text{softmax}\left(\frac{(W_q h_0)(W_k E)^\top}{\sqrt{d}}\right), \quad r = \alpha (W_v E). \quad (4)$$

Cuối cùng, ba vector được fuse thành $r = W_r[r_{\text{exp}}; r_{\text{imp}}; r_{\text{atk}}] + b_r$.

4.6 Batched attention (ghi chú triển khai)

Trong quá trình tái triển khai, nhóm nhận thấy một attention kiểu AmpleHate nếu tính bằng $QK^\top$ trên toàn bộ batch ($Q, K \in \mathbb{R}^{B \times d} \Rightarrow QK^\top \in \mathbb{R}^{B \times B}$) thì có thể trộn lẫn thông tin giữa các mẫu. Vì vậy, nhóm chuyển sang batched attention để mỗi mẫu chỉ attend đến các token của chính nó, với $Q \in \mathbb{R}^{B \times 1 \times d}$, $K \in \mathbb{R}^{B \times m \times d}$:

$$\text{scores} = \text{bmm}(Q, K^\top) / \sqrt{d} \in \mathbb{R}^{B \times 1 \times m}, \quad (5)$$

trong đó phần padding được mask trước softmax ($\text{scores}_j = -\infty$ nếu $\text{mask}_j = 0$). Nhóm coi đây chỉ là một chỉnh sửa ở mức triển khai cho bản port của mình, chứ không phải một khẳng định về AmpleHate gốc, nên trình bày như một ghi chú triển khai thay vì đánh giá riêng lẻ.

4.7 Instance-adaptive relation gate

Nhóm thay hệ số vô hướng cố định bằng một gate điều chỉnh theo từng mẫu:

$$g = \sigma(W_g[h_0; r] + b_g), \quad z = h_0 + g \cdot r. \quad (6)$$

Khi tín hiệu rõ ràng, mô hình nâng g để dựa nhiều hơn vào relation vector; khi cue yếu hoặc không có, nó hạ g và nghiêng về biểu diễn toàn cục. Vector z sau khi fuse sẽ đi qua dropout rồi một linear layer để tạo ra logit.




Figure 1: Kiến trúc tổng thể của ViAmpleHate. Bình luận được chuẩn hóa, tách từ và encode bởi PhoBERT thành các hidden state $H = [h_0, \dots, h_n]$, với h_0 là biểu diễn [CLS] (toàn cục). NER tiếng Việt và một target-cue bank tạo ra tập chỉ số target T_x , còn một attack-cue bank tạo ra A_x (fallback về [CLS] khi một tập rỗng). Một relation-bank attention với ba kênh theo từng mẫu—target tường minh (r_{exp}), context hàm ẩn (r_{imp}), và attack (r_{atk})—được fuse thành một relation vector duy nhất r và inject vào h_0 qua một instance-adaptive gate ($g = \sigma(W_g[h_0; r])$, $z = h_0 + gr$). Một linear classifier với threshold được tinh chỉnh trên tập validation cho ra quyết định NON-HATE/HATE; quá trình huấn luyện cực tiểu hóa $L = L_{\text{CE}} + \alpha L_{\text{CL}}$.

4.8 Hàm mục tiêu huấn luyện

Nhóm huấn luyện với $L = L_{\text{CE}} + \alpha L_{\text{CL}}$, $\alpha = 0.1$. Weighted cross-entropy $L_{\text{CE}} = -\sum_c w_c y_c \log \hat{y}_c$ xử lý mất cân bằng bằng cách tăng trọng số cho lớp HATE, kèm label smoothing (giá trị các class weight w_c , label smoothing và margin m ở dưới được nêu trong Phụ lục A). Số hạng contrastive trên z (với $s_{ij} = \cos(z_i, z_j)$) kéo các cặp cùng lớp lại gần nhau và đẩy các cặp khác lớp ra xa:

$$L_{\text{CL}} = \frac{1}{N} \sum_{i \neq j} [\mathbb{I}[y_i=y_j](1 - s_{ij}) + \mathbb{I}[y_i \neq y_j] \max(0, s_{ij} - m)]. \quad (7)$$

4.9 Inference và chọn threshold

Khi inference, nhóm dùng một decision threshold được chọn trên tập validation theo hướng cực đại hóa macro-F1, rồi cố định nó cho tập test:

$$t^* = \arg \max_t \text{MacroF1}(y, \mathbb{I}[p_{\text{HATE}} \geq t]). \quad (8)$$

4.10 Cân nhắc tính toán

So với PhoBERT, các thành phần thêm vào khá nhẹ: ba HeadAttention module và gate chỉ thao tác trên query [CLS] đã pool cùng vài cue token của mỗi mẫu, nên chi phí phát sinh chỉ là một ít linear projection; ngoài ra, batched attention đã chỉnh sửa còn rẻ hơn khi huấn luyện nhờ bỏ được tương tác $B \times B$ giả

tạo. Việc khớp cue cũng chỉ chạy một lần ở bước tiền xử lý.

5 Thực nghiệm

5.1 Các baseline

Nhóm so sánh với năm baseline, tất cả đều ở dạng nhị phân. **TF-IDF + LR** và **TF-IDF + SVM** dùng đặc trưng từ vựng thưa. **BiLSTM + fastText** (Bojanowski et al., 2017) kết hợp embedding tĩnh với một mô hình recurrent. **PhoBERT-CNN** xếp chồng CNN feature extractor lên PhoBERT. **AmpleHate-PhoBERT** là bản port của mô hình gốc với NER tiếng Anh, một HeadAttention đơn và injection cố định $z = h_0 + e r_{\text{base}}$ ($e = 1.0$), dùng chung encoder PhoBERT-base. Như trình bày trong Bảng 2, mỗi mô hình được chạy ở đúng cấu hình dự kiến của nó—ViAmpleHate cố ý dùng context window dài hơn (256) và effective batch lớn hơn, vốn là một phần của hệ thống đề xuất. Vì vậy, phép so sánh ở đây là giữa toàn bộ hệ thống đề xuất với baseline ở cấu hình tương ứng, chứ không nhằm cô lập đóng góp của từng thành phần.

5.2 Chi tiết triển khai

Encoder là `vinai/phobert-base` (768-d) và NER tiếng Việt là `NlpHUST/ner-vietnamese-electra-base`. Max length đặt ở 256; learning rate là $2e-5$ cho encoder và $5e-5$ cho head; dropout 0.1;

Thành phần	Baseline AmpleHate-PhoBERT	ViAmpleHate-PhoBERT (đề xuất)
Encoder	PhoBERT-base	PhoBERT-base
Trích xuất target	NER tiếng Anh	NER tiếng Việt + target-cue bank
Độ phủ target	$\approx 0,09\%$ tập train (21/24.048)	$\approx 18,8-20,0\%$ qua cue tiếng Việt
Tín hiệu attack	Không mô hình hóa	Attack-cue bank riêng
Attention	Một HeadAttention	Ba kênh: target / implicit / attack
Tính attention	<code>matmul</code> mức batch (trộn mẫu)	<code>bmm</code> theo mẫu + masking
Fusion	Injection cố định $h_0 + e r$ ($e=1.0$)	Relation bank + adaptive gate $h_0 + g r$
Loss	Weighted CE	Weighted CE + contrastive ($\alpha=0.1$)
Max length	128	256
Batch	16	$16 \times \text{grad-accum } 2$ (eff. 32)
NER khi đánh giá	Off ($\Rightarrow$ fallback [CLS])	On, nhất quán giữa các tập

Table 2: So sánh kiến trúc và cấu hình giữa baseline và mô hình đề xuất.

effective batch là 32 ($16 \times \text{grad-accum } 2$). Nhóm huấn luyện tối đa tám epoch và giữ lại checkpoint tốt nhất theo macro-F1 trên tập validation; $\alpha = 0.1$ và threshold cũng được chọn trên validation theo macro-F1. Toàn bộ hyperparameter được liệt kê trong Phụ lục A.

5.3 Độ đo đánh giá

Hai độ đo chính là macro-F1 và HATE-F1, vốn phản ánh hiệu năng trên lớp thiểu số tốt hơn nhiều so với accuracy: khi mẫu dương chỉ chiếm $\approx 10\%$, một bộ dự đoán luôn chọn lớp đa số đã đạt hơn 0,89 accuracy dù không phát hiện được trường hợp thù ghét nào. Macro-F1 lấy trung bình F1 trên các lớp, còn HATE-F1 tách riêng lớp mà nhóm quan tâm.

5.4 Thiết kế thực nghiệm

Ngoài điểm số cuối cùng, nhóm còn muốn kiểm tra xem mỗi thay đổi có thực sự khắc phục một hạn chế cụ thể của baseline hay không—from độ phủ thấp, việc chưa mô hình hóa sự thù địch, đến cách hợp nhất tín hiệu và hàm mất mát. Riêng độ phủ target được khảo sát trực tiếp ở Mục 6.2.

6 Kết quả và Phân tích lỗi

6.1 Kết quả chính

Mỗi mô hình được báo cáo ở đúng cấu hình dự kiến của nó (Mục 3.3, Bảng 2), nên các dòng đề xuất so với baseline phản ánh việc so sánh toàn bộ hệ thống đề xuất với baseline ở cấu hình tương ứng. Mọi con số đều đến từ một lần chạy duy nhất (seed 42).

Các mô hình transformer vượt trội rõ rệt so với baseline từ vệtng và embedding tĩnh ở những độ đo quan trọng (Bảng 3), cho thấy biểu diễn ngữ cảnh thực sự cần thiết khi thù

(a) ViHSD (test)

Mô hình	Acc.	Mac-F1	HATE-F1
TF-IDF + LR	0.8910	0.7393	0.5404
TF-IDF + SVM	0.9126	0.7131	0.4739
BiLSTM + fastText	0.8454	0.7072	0.5060
PhoBERT-CNN	0.8945	0.7571	0.5745
AmpleHate	0.9175	0.7792	0.6045
ViAmpleHate	0.9205	0.7819	0.6081
Δ vs base	$+0.0030$	$+0.0027$	$+0.0036$

(b) VOZ-HSD (test)

Mô hình	Acc.	Mac-F1	HATE-F1
TF-IDF + LR	0.9453	0.7745	0.5783
TF-IDF + SVM	0.9641	0.7831	0.5850
BiLSTM + fastText	0.8650	0.6712	0.4187
PhoBERT-CNN	0.9623	0.8150	0.6500
AmpleHate	0.9643	0.8185	0.6557
ViAmpleHate	0.9420	0.8371	0.7065
Δ vs base	-0.0223	$+0.0186$	$+0.0508$

Table 3: Kết quả trên tập test của ViHSD (a) và VOZ-HSD (b); AmpleHate là baseline, Δ là chênh lệch của ViAmpleHate so với baseline. Giá trị tốt nhất mỗi cột được in đậm (accuracy chỉ để tham khảo—riêng VOZ-HSD, baseline có accuracy cao nhất). Tất cả đều từ một lần chạy (seed 42).

ghét phụ thuộc vào context, cách diễn đạt phi chính thức và tương tác giữa lời nhắc tới với vị từ thù địch. Trong nhóm transformer, baseline AmpleHate nhỉnh hơn một PhoBERT classifier thuần nhờ target-aware attention, nhưng lợi ích bị giới hạn vì NER tiếng Anh hiếm khi tìm được target tiếng Việt hợp lệ, khiến hầu hết đầu vào quay về [CLS]. Nhóm chỉ so sánh với các mô hình tự huấn luyện theo cùng một giao thức; việc đối chiếu với kết quả ViHSD đã công bố xin dành cho công trình tương lai.

Trên VOZ-HSD, ViAmpleHate cải thiện cả macro-F1 lẫn HATE-F1 với biên độ rõ ràng (HATE-F1 +0,0508). Trên ViHSD, khác biệt nhỏ hơn nhiều (+0,0027 macro-F1, +0,0036 HATE-F1); và vì mọi số liệu chỉ đến từ một lần chạy (seed 42), chưa có kiểm định ý nghĩa thống kê, nên nhóm chỉ coi mức tăng trên ViHSD là sơ bộ. Đáng lưu ý, accuracy lại *giảm* trên VOZ-HSD trong khi macro-F1 và HATE-F1 đều tăng—một minh chứng cho thấy vì sao accuracy là độ đo dễ gây hiểu nhầm khi dữ liệu mất cân bằng.

6.2 Tác động của trích xuất target tiếng Việt

Một yếu tố có thể góp phần là độ phủ target—tỷ lệ bình luận có $T_x \neq \{0\}$ (NER tiếng Việt hoặc một target cue kích hoạt). Với NER tiếng Anh, chỉ $\approx 0,09\%$ bình luận train có target (21/24.048), nên nhánh target-aware của baseline gần như không hoạt động. Khi dùng NER tiếng Việt cùng target-cue bank, độ phủ target tăng lên 20,0%/18,8% trên 500 bình luận train/validation đầu của ViHSD và 45,2%/43,0% trên VOZ-HSD (cùng bank 16 cue); độ phủ attack cue thấp hơn—5,2%/4,2% (ViHSD) và 7,6%/6,0% (VOZ). Đáng chú ý, bộ có độ phủ cao hơn (VOZ-HSD) cũng là nơi ViAmpleHate cải thiện nhiều nhất (HATE-F1 +0,0508 so với +0,0036)—một tương quan gợi mở. Tuy vậy, độ phủ chỉ là thống kê *đầu vào*: nó cho relation-bank attention nhiều thứ để attend hơn, nhưng chưa đủ chứng minh việc kích hoạt giúp cải thiện từng quyết định.

6.3 Phân tích định tính

Để minh họa cụ thể các kiểu lỗi, Bảng 4 liệt kê một số dạng bình luận tiêu biểu (đây là ví dụ dựng lại theo các phạm trù quan sát được; ở bản camera-ready nên thay bằng mẫu test thực đã ẩn danh). Xu hướng chung là ViAmpleHate




Figure 2: Đường cong training/validation của ViAmpleHate trên ViHSD (best epoch 4, macro-F1 trên validation = 0,7852). training_curves_viamplehate.png.

Kiểu bình luận	Tgt	Atk	Gold
Nhân nhóm + vị từ thù địch	yes	yes	HATE
Lời tục, không target nhóm	no	yes	NON
Mĩa mai/hàm ẩn, không cue lộ	no	no	HATE
Nhân nhóm trong context trung tính	yes	no	NON

Table 4: Các trường hợp minh họa (được dựng nên; thay bằng ví dụ thực). Tgt/Atk = có hiện diện target/attack cue.

hỗ trợ tốt nhất khi một target tường minh đi kèm một attack predicate, và kém nhất với những trường hợp thù ghét hàm ẩn—không nêu target nào và cũng không có từ attack lộ liễu.

6.4 Thảo luận

Có ba điểm đáng chú ý. Thứ nhất, trên ViHSD, thay đổi nghiêng về tái cân bằng precision/recall hơn là một mức tăng đồng đều: precision của HATE tăng (0,5972 $\rightarrow$ 0,6177) còn recall *giảm* (0,6119 $\rightarrow$ 0,5988). Precision cao hơn được ưa chuộng khi cáo buộc nhầm

Dữ liệu	Lớp	P	R	F1
ViHSD	NON-HATE	0.9541	0.9574	0.9558
ViHSD	HATE	0.6177	0.5988	0.6081
VOZ	NON-HATE	0.9638	0.9719	0.9678
VOZ	HATE	0.7347	0.6803	0.7065

Table 5: Kết quả theo từng lớp của ViAmpleHate (tập test, một lần chạy).




Figure 3: Confusion matrix trên ViHSD: AmpleHate baseline (trái) so với ViAmpleHate (phải). `confusion_matrix_amplehate.png` và `confusion_matrix_viamplehate.png`; lưu ý sự giảm số false positive của lớp HATE.

phải trả giá đắt, nhưng recall thấp hơn nghĩa là bỏ sót nhiều hơn—tùy bối cảnh triển khai mà chọn. Nhóm chỉ báo cáo ở một threshold đơn và để dành phân tích precision–recall đầy đủ cho sau. Trên VOZ-HSD, nơi độ phủ cao hơn, recall của HATE cũng cao hơn (0,6803; Bảng 5). Thứ hai, mức tăng lớn hơn trên VOZ-HSD đi kèm accuracy giảm cho thấy mô hình đánh đổi accuracy của lớp đa số để lấy chất lượng cho lớp thiểu số—điều thường được mong đợi khi lớp thiểu số là trọng tâm. Thứ ba, quan hệ giữa độ phủ cue và mức cải thiện gợi mở một hướng nâng cấp ít tốn kém—mở rộng và tinh chỉnh cue bank—dù vẫn cần kiểm chứng thêm (Mục 6.2).

6.5 Phân tích lỗi

Nhóm chia các lỗi còn lại thành bảy nhóm thường gặp. **(1) Xúc phạm nhưng không phải thù ghét:** lời lăng mạ hay lời tục nhắm vào một cá nhân chứ không phải một nhóm được bảo vệ; khi mô hình đề cao attack cue quá mức sẽ sinh ra false positive. **(2) Thù ghét hàm ẩn:** bình luận không có slur, thực thể có tên hay attack predicate lộ liễu, mà thể hiện thù địch qua mỉa mai, định kiến hoặc ngữ cảnh xã hội chung; lúc này việc trích cue gần như không tìm được gì để attend. **(3) Tham chiếu target mơ hồ:** đại từ và danh từ chỉ nhóm cũng xuất hiện trong những bình luận trung tính hoặc hài hước, nên một target cue thiếu ngữ cảnh thù địch dễ khiến mô hình dự đoán nhầm thành HATE. **(4) Cue chưa phủ đủ:** tiếng lóng thay đổi nhanh, biến thể chính

tả, viết tắt, lời tục sáng tạo hoặc bị kiểm duyệt là những thứ một cue bank cố định khó bao quát hết, dẫn tới false negative. **(5) Lệnh token và span:** span của NER, kết quả tách từ và subword tokenization của PhoBERT có thể không trùng khớp—nhất là với các cụm nhiều từ—nên một cue đôi khi khớp sai vị trí. **(6) Nhạy cảm với threshold:** threshold tinh chỉnh trên validation có thể không còn phù hợp khi phân phối dữ liệu thay đổi. **(7) Mất cân bằng lớp:** với quá ít mẫu dương, lỗi ở lớp thiểu số vẫn dai dẳng dù đã dùng weighted loss và tinh chỉnh threshold. Hướng khắc phục: mở rộng cue bank qua khai thác dữ liệu kèm kiểm chứng thủ công, ghi log dự đoán theo mẫu (gate, độ phủ cue, confidence) để phân tích false positive/negative, thêm span supervision hoặc phát hiện mỉa mai, và áp dụng probability calibration.

7 Kết luận và Hướng phát triển

ViAmpleHate thích ứng AmpleHate cho tiếng Việt qua trích xuất target tiếng Việt, tách riêng hai kênh target/attack cue, relation-bank attention và relation injection thích ứng (kèm một chỉnh sửa batched-attention ở mức triển khai), huấn luyện bằng weighted cross-entropy cộng contrastive loss. Trên ViHSD và VOZ-HSD, mô hình cải thiện cả macro-F1 lẫn HATE-F1 so với baseline AmpleHate và các baseline TF-IDF, BiLSTM, PhoBERT-CNN, rõ nhất ở lớp thiểu số của VOZ-HSD; mức tăng trên ViHSD còn nhỏ và cần xác nhận lại bằng so sánh đa seed. Phân tích cho thấy các mức cải

thiện gắn với độ phủ target—thứ mà cue bank tiếng Việt nâng lên khoảng hai bậc độ lớn so với NER tiếng Anh—song đây mới là liên hệ tương quan, chưa thể khẳng định nhân quả. Bài học rộng hơn: target-aware chỉ phát huy khi được thích ứng với hình thái bề mặt của ngôn ngữ đích. Hướng phát triển tiếp theo gồm tự động khai thác cue bank kèm kiểm chứng thủ công, phân tích lỗi mức từng mẫu, bổ sung span supervision và phát hiện mĩa mai, mở rộng sang multi-label/multi-target theo tinh thần ViTHSD, và áp dụng probability calibration cho ổn định khi chuyển miền.

References

- Piotr Bojanowski, Edouard Grave, Armand Joulin, and Tomas Mikolov. 2017. Enriching word vectors with subword information. *Transactions of the Association for Computational Linguistics*, 5:135–146.
- Prannay Khosla, Piotr Teterwak, Chen Wang, Aaron Sarna, Yonglong Tian, Phillip Isola, Aaron Maschinot, Ce Liu, and Dilip Krishnan. 2020. Supervised contrastive learning. In *Advances in Neural Information Processing Systems (NeurIPS)*.
- Yejin Lee, Joonghyuk Hahn, Hyeseon Ahn, and Yo-Sub Han. 2025. [AmpleHate: Amplifying the attention for versatile implicit hate detection](#). In *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*, pages 28862–28874, Suzhou, China. Association for Computational Linguistics.
- Son T. Luu, Kiet Van Nguyen, and Ngan Luu-Thuy Nguyen. 2021. [A large-scale dataset for hate speech detection on vietnamese social media texts](#). In *Advances and Trends in Artificial Intelligence. Artificial Intelligence Practices*, volume 12798 of *Lecture Notes in Computer Science*, pages 415–426, Cham. Springer.
- Dat Quoc Nguyen and Anh Tuan Nguyen. 2020. PhoBERT: Pre-trained language models for Vietnamese. In *Findings of the Association for Computational Linguistics: EMNLP 2020*, pages 1037–1042.
- Luan Thanh Nguyen. 2024a. [ViHateT5: Enhancing hate speech detection in vietnamese with a unified text-to-text transformer model](#). In *Findings of the Association for Computational Linguistics: ACL 2024*, pages 5948–5961, Bangkok, Thailand. Association for Computational Linguistics.
- Luan Thanh Nguyen. 2024b. [VOZ-HSD: A hate speech detection dataset from the voz forum](#). Hugging Face dataset. Dataset released with the paper ViHateT5: Enhancing Hate Speech Detection in Vietnamese with a Unified Text-to-Text Transformer Model.
- Cuong Nhat Vo, Khanh Bao Huynh, Son T. Luu, and Trong-Hop Do. 2025. [ViTHSD: Exploiting hatred by targets for hate speech detection on vietnamese social media texts](#). *Journal of Computational Social Science*, 8(2):30.

A Hyperparameter

Tham số	Giá trị
Encoder	vinai/phobert-base (768-d)
NER tiếng Việt	NlpHUST/ ner-vietnamese- electra-base
max_len	256
LR (encoder / head)	2e-5 / 5e-5
Dropout	0.1
Effective batch	32 (16 × grad-accum 2)
Epoch	tối đa 8 (tốt nhất theo macro-F1 trên val)
α (contrastive)	0.1
Class weight w_c	inverse freq. $N/(C n_c)$
Contrastive margin m	0.5
Label smoothing	0.05
Seed / số lần chạy	42 / một lần chạy
ViHSD best epoch / val F1 / thr.	4 / 0.7852 / 0.43

Table 6: Toàn bộ hyperparameter.

B Ví dụ cue bank

Toàn bộ hai bank—16 target cue và 24 attack cue—được phát hành kèm mã nguồn và liệt kê đầy đủ trong báo cáo đi kèm; ở đây nhóm chỉ nêu vài ví dụ an toàn ASCII. **Target cue** mang tính tham chiếu và bản thân không hàm ý thù ghét: các cách gọi người/nhóm phi chính thức, nhân vùng miền và nhân khẩu, đại từ nhóm. **Attack cue** là các vị từ thù địch thể hiện sự khinh miệt, phi nhân tính hóa hay ăn bám (ví dụ **khinh**, **an_bam**). Hai loại cue này được lưu ở các bank tách biệt (Mục 3.4).

C Khả năng tái lập

Mọi mô hình dựa trên PhoBERT đều dùng chung **vinai/phobert-base**; điểm khác nhau giữa baseline và ViAmpleHate chỉ nằm ở cách mô hình hóa target/relation, phép tính attention, fusion và loss. Checkpoint tốt nhất được chọn theo macro-F1 trên validation, còn threshold cho lớp HATE được chọn trên validation rồi cố định cho test. Việc khớp cue chỉ chạy một lần ở bước tiền xử lý, theo kiểu khớp trọn chuỗi token với dòng token của PhoBERT.