



ViAmpleHate


A Proposed AmpleHate- and PhoBERT-based Approach for Vietnamese Hate

Nhóm sinh viên:

23521687 Trần Nguyễn Đức Trung
23521718 Nguyễn Hà Minh Tuấn
23520881 Nguyễn Gia Cát Long
23521747 Trần Phan Thanh Tùng
23521741 Mô Văn Tùng

GVHD:

ThS. Huỳnh Văn Tín



Abstract

1. Giới thiệu

2. Các nghiên cứu liên quan

3. Bộ dữ liệu

4. Phương pháp

5. Thực nghiệm

6. Phân tích kết quả và lỗi

7. Kết luận và hướng phát triển



ViAmpleHate

ViAmpleHate Đề xuất phương pháp tiếp cận mới dựa trên AmpleHate và PhoBERT cho bài toán phát hiện hate speech Tiếng Việt





Tóm tắt

Phát hiện hate speech trên mạng xã hội tiếng Việt là một bài toán khó, vì ý định thù ghét thường được thể hiện một cách gián tiếp thông qua cách gọi nhóm, tiếng lóng, châm biếm hoặc hàm ý, thay vì xuất hiện rõ ràng dưới dạng named entities.. Mặc dù AmpleHate cho thấy việc mô hình hóa mối quan hệ giữa câu nói và target có thể cải thiện khả năng phát hiện implicit hate, nhưng English NER và các nhóm target theo ngữ cảnh tiếng Anh lại không phù hợp khi áp dụng trực tiếp cho tiếng Việt. Trên training data của nhóm, English NER chỉ tìm được target có thể sử dụng trong khoảng 0.09% bình luận, khiến mô hình gần như chỉ hoạt động như một bộ phân loại câu thông thường.

Nhóm đề xuất ViAmpleHate, một phiên bản điều chỉnh từ AmpleHate cho tiếng Việt, sử dụng PhoBERT, thay English NER bằng Vietnamese NER và các bộ target cues / attack cues được xây dựng thủ công. Cách tiếp cận này giúp tăng tỷ lệ phát hiện target từ khoảng 0.09% lên khoảng 19–45%, tùy theo bộ dữ liệu.. Mô hình kết hợp thông tin từ explicit target, implicit context và attack relations thông qua relation-bank attention cùng với instance-adaptive gate. Trên hai bộ dữ liệu ViHSD và VOZ-HSD, ViAmpleHate cải thiện Macro-F1 và HATE-F1 so với AmpleHate, TF-IDF, BiLSTM và PhoBERT-CNN. Mức cải thiện rõ nhất nằm ở VOZ-HSD, với HATE-F1 tăng +0.0508; kết quả trên ViHSD nhỏ hơn và được xem là kết quả sơ bộ.






1.

Giới thiệu

Bối cảnh và thách thức

Phát hiện hate speech tiếng Việt gặp nhiều khó khăn vì ngôn ngữ trên mạng xã hội thường nhiễu, không trang trọng và còn có thể bị cố ý viết lệch.



Hate speech hiếm khi xuất hiện trực tiếp thông qua named entities rõ ràng. Thay vào đó, nội dung thù ghét thường nhắm đến các nhóm người một cách gián tiếp qua đại từ, cách xưng hô, từ chỉ vùng miền, tiếng lóng, châm biếm hoặc các cách gọi thân mật. Ngoài ra, các bộ dữ liệu cũng bị mất cân bằng mạnh, khi lớp HATE chỉ chiếm khoảng một phần mười tổng số bình luận.



1. Giới thiệu

Mô hình ViAmpleHate đề xuất

Nhóm đề xuất ViAmpleHate, một phiên bản điều chỉnh từ AmpleHate, sử dụng PhoBERT cho bài toán phát hiện hate speech tiếng Việt.

Ý tưởng chính

Mô hình thay English NER bằng Vietnamese NER và các bộ target cues được xây dựng thủ công, giúp tăng tỷ lệ phát hiện target từ khoảng 0.09% lên 18.8–20.0%.

Các cải tiến khác

ViAmpleHate tách riêng target cues và attack cues, sử dụng relation-bank attention với adaptive fusion, đồng thời kết hợp weighted cross-entropy và contrastive loss để cải thiện khả năng phân loại HATE/NON-HATE.



2. Các nghiên cứu liên quan




Hate speech detection và implicit hate

Các phương pháp phát hiện hate speech tự động đã phát triển từ những cách tiếp cận dựa trên lexicon sang deep learning và pretrained transformers. Tuy nhiên, implicit hate vẫn là một bài toán khó, vì thái độ thù ghét thường được thể hiện thông qua châm biếm, định kiến, cách nói ẩn dụ hoặc hiểu biết xã hội ngầm, thay vì các từ xúc phạm trực tiếp.



Vietnamese Hate Speech Detection

Hate speech tiếng Việt thường phụ thuộc vào những cách nhắc đến target không chính thức như đại từ, danh từ chỉ nhóm và cách xưng hô. Các bộ dữ liệu hiện có cho thấy thông tin về target là rất quan trọng. Tuy nhiên, ViAmpleHate không yêu cầu span-level annotation; thay vào đó, mô hình sử dụng Vietnamese NER và cue banks để xác định vị trí target và attack.



Contrastive Learning for Text Classification

Contrastive learning giúp đưa các biểu diễn cùng lớp lại gần nhau hơn và đẩy các biểu diễn khác lớp ra xa nhau hơn. ViAmpleHate kết hợp weighted cross-entropy với một contrastive auxiliary objective nhằm cải thiện khả năng phân tách giữa lớp NON-HATE phổ biến và lớp HATE ít xuất hiện hơn.

2. Các nghiên cứu liên quan




AmpleHate

AmpleHate phát hiện ngôn từ thù ghét ngấm bằng cách mô hình hóa mối quan hệ giữa câu và các mục tiêu ứng viên. Mô hình dùng NER để trích xuất từ chỉ mục tiêu, sau đó áp dụng cơ chế chú ý có nhận thức mục tiêu trước khi phân loại. Tuy nhiên, AmpleHate phụ thuộc vào NER tiếng Anh, cơ chế bổ sung quan hệ cố định, và chỉ tập trung vào dấu hiệu mục tiêu mà bỏ qua dấu hiệu công kích.




Fine-tuned Models for
vinai/phobert-base


huggingface.co/models



PhoBERT and Vietnamese Pretrained Models

PhoBERT là mô hình mã hóa tiền huấn luyện mạnh cho các bài toán phân loại văn bản tiếng Việt. Vì PhoBERT được huấn luyện trên văn bản tiếng Việt đã tách từ, văn bản cần được tách từ trước khi token hóa. ViAmpleHate sử dụng PhoBERT-base làm bộ mã hóa chung, nhờ đó các cải tiến chủ yếu đến từ mô hình hóa có nhận thức mục tiêu thay vì từ backbone.






ViHSD VOZ-HSD

Dataset	Split	NON-HATE	HATE	Total
ViHSD	Train	21,492	2,556	24,048
ViHSD	Dev	2,402	270	2,672
ViHSD	Test	5,992	688	6,680
VOZ	Train	26,993	3,007	30,000
VOZ	Dev	4,520	480	5,000
VOZ	Test	4,487	513	5,000

Bài toán được chuyển thành phân loại nhị phân bằng cách gộp hai lớp CLEAN và OFFENSIVE thành NON-HATE, trong khi lớp HATE được giữ làm lớp dương. Không có mẫu dữ liệu nào bị loại bỏ hoặc lấy mẫu lại.

3. Bộ dữ liệu

Các bình luận được chuẩn hóa thông qua các bước: chuyển về chữ thường, loại bỏ URL/ký hiệu, rút gọn các từ bị kéo dài, chuẩn hóa teencode và ánh xạ emoji. Sau đó, dữ liệu được word-segmented và tokenized bằng PhoBERT.





```
TARGET_CUES = [  
    'bọn', 'thằng', 'con', 'đứa', 'tụi', 'đám', 'lũ',  
    'mấy', 'loại', 'người', 'dân', 'bên',  
    'hắn', 'chúng', 'họ', 'nó',  
]  
  
ATTACK_CUES = [  
    'ngu', 'đần', 'ngu-ngốc', 'khùng', 'điên', 'hèn', 'nhục',  
    'ăn_bám', 'kỳ_sinh', 'phản_quốc', 'vô_học', 'man_rợ',  
    'cút', 'xéo', 'câm_miệng',  
    'giết', 'chém', 'đánh',  
    'ghét', 'khinh', 'chửi',  
    'vô_văn_hóa', 'thấp_hèn', 'đáng_chết',  
]
```

ViAmpleHate sử dụng hai cue banks được xây dựng thủ công: target cues và attack cues. Target cues chỉ người hoặc nhóm người, trong khi attack cues gồm các từ xúc phạm, đe dọa, phi nhân hóa và đánh giá tiêu cực.


3. Bộ dữ liệu


Tất cả cues được chuẩn hóa, word-segmented, tokenized và được so khớp dưới dạng chuỗi token đầy đủ. Hai banks cuối cùng gồm 16 target cues và 24 attack cues, nhưng vẫn có thể bị hạn chế bởi training-data bias và độ bao phủ thấp đối với các từ lóng mới.





4. Phương pháp đề xuất





5. Thực nghiệm

Baseline models

Machine Learning

- TFIDF + LR and TF-IDF + SVM

Neural Network Model with Static Embeddings

- BiLSTM + fastText

<https://fasttext.cc/docs/en/crawl-vectors.html>


PhoBERT-based Deep Learning Models

- PhoBERT-CNN

Original Approach

- AmpleHate-PhoBERT

['dbmdz/bert-large-cased-finetuned-conll03-english'](#)



5. Thực nghiệm

Baseline models

VAmplateHate – PhoBERT

encoder

vinai/phobert-base

huggingface.co/models

Vietnamese NER

 **NlpHUST/ner-vietnamese-electra-base**



Token Classification



Transformers



PyTorch



Sa



Model card



Files and versions




xet



Commur

Vietnamese NER

Parameter	Value
Encoder	vinai/phobert-base (768-d)
Vietnamese NER	NlpHUST/ner-vietnamese-electra-base
max_len	256
LR (encoder / head)	2e-5 / 5e-5
Dropout	0.1
Effective batch	32 (16 × grad-accum 2)
Epochs	up to 8 (best by val macro-F1)
α (contrastive)	0.1
Class weights w_c	inverse freq. $N/(C n_c)$
Contrastive margin m	0.5
Label smoothing	0.05
Seed / runs	42 / single run



5. Thực nghiệm

Model	Acc.	Mac-F1	HATE-F1
TF-IDF + LR	0.8910	0.7393	0.5404
TF-IDF + SVM	0.9126	0.7131	0.4739
BiLSTM + fastText	0.8454	0.7072	0.5060
PhoBERT-CNN	0.8945	0.7571	0.5745
AmpleHate (baseline)	0.9175	0.7792	0.6045
ViAmpleHate	0.9205	0.7819	0.6081
$\Delta base$	$+.0030$	$+.0027$	$+.0036$

Table 3: Results on ViHSD (test). Best per column in bold (accuracy shown for reference). Single run (seed 42).

Model	Acc.	Mac-F1	HATE-F1
TF-IDF + LR	0.9453	0.7745	0.5783
TF-IDF + SVM	0.9641	0.7831	0.5850
BiLSTM + fastText	0.8650	0.6712	0.4187
PhoBERT-CNN	0.9623	0.8150	0.6500
AmpleHate (baseline)	0.9643	0.8185	0.6557
ViAmpleHate	0.9420	0.8371	0.7065
$\Delta base$	$-.0223$	$+.0186$	$+.0508$

Table 4: Results on VOZ-HSD (test). Best per column in bold among models (accuracy shown for reference; the baseline has the highest accuracy). Single run (seed 42).



5. Thực nghiệm

Dataset	Model	Accuracy	Macro Precision	Macro Recall	Macro F1	HATE Precision	HATE Recall	HATE F1
ViHSD	TF-IDF + SVM (Tuned)	0.9126	0.78	0.68	0.7131	0.62	0.38	0.4739
ViHSD	TF-IDF + LR (Tuned)	0.891	0.72	0.77	0.7393	0.48	0.62	0.5404
ViHSD	BiLSTM - FastTextVi	0.8454	0.6735	0.8115	0.7072	0.377	0.7689	0.506
ViHSD	PhoBert CNN	0.8945	0.7271	0.8048	0.7571	0.4912	0.6919	0.5745
ViHSD	PhoBert AmpleHate Origin	0.9175	0.7762	0.7823	0.7792	0.5972	0.6119	0.6045
ViHSD	PhoBert ViAmpleHate	0.9205	0.7859	0.7781	0.7819	0.6177	0.5988	0.6081
VOZ-HSD	TF-IDF + SVM (Tuned)	0.9641	0.85	0.74	0.7831	0.72	0.49	0.585
VOZ-HSD	TF-IDF + LR (Tuned)	0.9453	0.73	0.84	0.7745	0.48	0.73	0.5783
VOZ-HSD	BiLSTM - FastTextVi	0.865	0.633	0.8851	0.6712	0.2721	0.9076	0.4187
VOZ-HSD	PhoBert CNN	0.9623	0.8021	0.8292	0.815	0.6217	0.6809	0.65
VOZ-HSD	PhoBert AmpleHate Origin	0.9643	0.8159	0.8211	0.8185	0.6501	0.6615	0.6557
VOZ-HSD	PhoBert ViAmpleHate	0.942	0.8492	0.8261	0.8371	0.7347	0.6803	0.7065



5. Thực nghiệm

Component	Baseline AmpleHate-PhoBERT	ViAmpleHate-PhoBERT (proposed)
Encoder	PhoBERT-base	PhoBERT-base
Target extraction	English NER	Vietnamese NER + target-cue bank
Target coverage	$\approx 0.09\%$ of train (21/24,048)	$\approx 18.8\text{--}20.0\%$ via Vietnamese cues
Attack signal	Not modeled	Separate attack-cue bank
Attention	One HeadAttention	Three channels: target / implicit / attack
Attention computation	Batch-level matmul (mixes samples)	Per-sample bmm + masking
Fusion	Fixed injection $h_0 + e r$ ($e=1.0$)	Relation bank + adaptive gate $h_0 + g r$
Loss	Weighted CE	Weighted CE + contrastive ($\alpha=0.1$)
Max length	128	256
Batch	16	$16 \times \text{grad-accum } 2$ (eff. 32)
NER at evaluation	Off ($\Rightarrow$ [CLS] fallback)	On, consistent across splits

Table 2: Architecture and configuration comparison between the baseline and the proposed model.



01 Kết quả chính

- ViAmpleHate đạt Macro-F1 và HATE-F1 cao nhất trên cả hai bộ dữ liệu ViHSD và VOZ-HSD.
- Trên ViHSD, mức cải thiện so với AmpleHate khá nhỏ: Macro-F1 tăng 0.0027 và HATE-F1 tăng 0.0036.
- Trên VOZ-HSD, mức tăng rõ rệt hơn: Macro-F1 tăng 0.0186 và HATE-F1 tăng 0.0508.
- Độ chính xác trên VOZ-HSD giảm, nhưng hiệu quả trên lớp thiểu số được cải thiện, cho thấy accuracy không phản ánh tốt hiệu năng khi dữ liệu mất cân bằng mạnh.

Data	Class	P	R	F1
ViHSD	NON-HATE	0.9541	0.9574	0.9558
ViHSD	HATE	0.6177	0.5988	0.6081
VOZ	NON-HATE	0.9638	0.9719	0.9678
VOZ	HATE	0.7347	0.6803	0.7065

Table 6: Per-class results of ViAmpleHate (test set, single run).

6. Phân tích kết quả

02 Ảnh hưởng của Vietnamese Target Extraction

- NER tiếng Anh chỉ phát hiện được mục tiêu hữu dụng trong khoảng 0.09% bình luận huấn luyện tiếng Việt, khiến nhánh nhận thức mục tiêu gốc của AmpleHate gần như không hoạt động.
- NER tiếng Việt kết hợp với các dấu hiệu mục tiêu giúp tăng độ bao phủ mục tiêu lên khoảng 18.8–20.0% trên ViHSD và 43.0–45.2% trên VOZ-HSD.
- Độ bao phủ của dấu hiệu công kích thấp hơn, nhưng vẫn cung cấp thêm tín hiệu để nhận diện các vị ngữ mang tính thù địch.
- Mức cải thiện lớn hơn trên VOZ-HSD phù hợp với độ bao phủ dấu hiệu mục tiêu cao hơn nhiều của bộ dữ liệu này.



03

Phân tích định tính

- ViAmpleHate hoạt động tốt nhất khi trong câu vừa có đối tượng rõ ràng, vừa có tín hiệu công kích đi kèm.
- Những câu có từ tục hoặc lời xúc phạm nhưng không nhắm vào một nhóm cụ thể thường không phải là phát ngôn thù ghét. Vì vậy, việc tách riêng tín hiệu đối tượng và tín hiệu công kích giúp giảm nhầm lẫn.
- Mô hình vẫn gặp khó khăn với các trường hợp thù ghét ngầm, mỉa mai hoặc châm biếm, đặc biệt khi không có đối tượng hoặc từ công kích rõ ràng.
- Các trường hợp chỉ nhắc đến nhóm người trong ngữ cảnh trung lập cũng dễ gây khó khăn, vì sự xuất hiện của target cue không đồng nghĩa chắc chắn với phát ngôn thù ghét.
- Những trường hợp này cho thấy mô hình hóa theo đối tượng là hữu ích, nhưng vẫn chưa đủ để xử lý toàn bộ các dạng phát ngôn thù ghét.

6. Phân tích kết quả

Comment type	Tgt	Atk	Gold
Group label + hostile predicate	yes	yes	HATE
Profanity, no group target	no	yes	NON
Sarcastic/implicit, no overt cue	no	no	HATE
Group label in neutral context	yes	no	NON

Table 5: Illustrative cases (constructed; replace with real examples). Tgt/Atk = target/attack cue present.



Phân tích lỗi





Figure 4: Confusion matrices on ViHSD: baseline AmpleHate (left) vs ViAmpleHate (right). `confusion_matrix_amplehate.png` and `confusion_matrix_viamplehate.png`; note the reduction in HATE false positives.



Phân tích lỗi

Các lỗi còn lại có thể chia thành bảy nhóm chính:



- Offensive nhưng không phải hate: Các câu chửi tục hoặc xúc phạm cá nhân có thể bị dự đoán nhầm thành HATE nếu mô hình đặt trọng số quá cao vào attack cues.



- Hate ngầm: Mỉa mai, định kiến hoặc ngôn ngữ mã hóa có thể thể hiện sự thù ghét mà không cần đối tượng hoặc từ công kích rõ ràng, khiến bước trích xuất cue bị thất bại.



- Tham chiếu đối tượng mơ hồ: Đại từ, danh từ chỉ nhóm người hoặc nhãn vùng miền có thể xuất hiện trong ngữ cảnh trung lập hoặc hài hước, gây ra false positives.



- Cue bank chưa bao phủ đầy đủ: Các cue bank cố định dễ bỏ sót tiếng lóng mới, biến thể chính tả, viết tắt và các cách che từ tục.

- Lỗi tokenization và căn chỉnh span: NER span, tách từ tiếng Việt và subword của PhoBERT có thể không khớp nhau, đặc biệt với các cụm từ nhiều từ.

- Nhạy cảm với ngưỡng phân loại: Ngưỡng được tối ưu trên validation set có thể không còn phù hợp khi miền dữ liệu test thay đổi.

- Mất cân bằng lớp: Lớp HATE chỉ chiếm khoảng 10%, nên lỗi ở lớp thiểu số vẫn khó xử lý dù đã dùng weighted loss và điều chỉnh threshold.

Các hướng cải thiện chính: Mở rộng cue banks. Ghi log lỗi theo từng mẫu cùng với gate value và confidence. Bổ sung span supervision hoặc phát hiện mỉa mai. Áp dụng calibration cho xác suất dự đoán



Hạn chế

Các hạn chế chính của nghiên cứu gồm:




- Độ bao phủ của cue bank: Target-cue bank và attack-cue bank được xây dựng một phần thủ công, nên chưa thể bao phủ hết tiếng lóng tiếng Việt, biến thể chính tả hoặc các cách chửi sáng tạo. Điều này làm hạn chế recall đối với phát ngôn thù ghét ngầm hoặc mới xuất hiện.



- Phụ thuộc vào tiền xử lý: Hiệu quả mô hình phụ thuộc vào NER tiếng Việt, tách từ và tokenization. Lỗi ở các bước này có thể làm cue bị đặt sai vị trí hoặc bị bỏ sót.



- Giới hạn của threshold: Ngưỡng quyết định được tinh chỉnh trên validation set và có thể không còn tối ưu khi phân phối dữ liệu thay đổi. Việc chỉ báo cáo một threshold cũng chưa thể hiện đầy đủ sự đánh đổi giữa precision và recall.



- Giới hạn thực nghiệm: Kết quả chỉ dựa trên một lần chạy với seed 42, chưa có đánh giá đa seed, kiểm định ý nghĩa thống kê hoặc ablation study theo từng thành phần. Vì vậy, mức cải thiện nhỏ trên ViHSD chưa thể được khẳng định chắc chắn.

- Giới hạn so sánh: Nghiên cứu so sánh với các baseline được nhóm tự cài đặt lại, thay vì so sánh trực tiếp với các kết quả ViHSD đã công bố.

- Phạm vi bài toán: Mô hình hiện chỉ xử lý phân loại nhị phân NON-HATE/HATE, chưa hỗ trợ phát hiện nhiều đối tượng hoặc các mức độ thù ghét khác nhau.



7. Kết luận và hướng phát triển

Conclusion

- ViAmpleHate điều chỉnh AmpleHate cho phát hiện ngôn từ thù ghét tiếng Việt bằng cách thay trích xuất mục tiêu thiên về tiếng Anh bằng NER tiếng Việt và cue banks.
- Mô hình tách riêng target cues và attack cues, sử dụng relation-bank attention, áp dụng adaptive relation gate và huấn luyện bằng weighted cross-entropy kết hợp contrastive loss.
- ViAmpleHate cải thiện Macro-F1 và HATE-F1 so với AmpleHate và các baseline khác. Mức cải thiện rõ nhất xuất hiện trên VOZ-HSD.
- Mức cải thiện trên ViHSD còn nhỏ và cần được xác nhận bằng các thực nghiệm đa seed có kiểm soát.
- Phân tích độ bao phủ cho thấy phát hiện phát ngôn thù ghét theo hướng target-aware cần được điều chỉnh theo đặc điểm ngôn ngữ của từng ngôn ngữ cụ thể.

Future Work

- Trong tương lai, có thể mở rộng cue banks, tự động khai thác cue mới kết hợp kiểm duyệt thủ công, phân tích lỗi bằng gate value và confidence, bổ sung span supervision và phát hiện mỉa mai, đưa thêm ngữ cảnh hội thoại, mở rộng sang bài toán multi-label và multi-target, đồng thời cải thiện calibration để triển khai tốt hơn trên nhiều miền dữ liệu.



THANK FOR YOUR LISTENING

Nhóm sinh viên:

23521687 Trần Nguyễn Đức Trung
23521718 Nguyễn Hà Minh Tuấn
23520881 Nguyễn Gia Cát Long
23521747 Trần Phan Thanh Tùng
23521741 Mô Văn Tùng

GVHD:

ThS. Huỳnh Văn Tín

ViAmpleHate

A Proposed AmpleHate- and
PhoBERT-based Approach for
Vietnamese Hate